

PROYECTO CLASIFICADOR DE EMOCIONES

ASIGNATURA

Aprendizaje Automático

PROFESOR

Santiago Hernández Torres

ESTUDIANTE

David Esteban Martín Acosta

Santiago Torres Gallego

Universidad Nacional de Colombia

Sede Medellín

2024 - 1

Índice

1. (5 %) Pregunta de investigación y objetivos	2
1.1. Objetivo Principal	2
1.2. Objetivos Específicos	2
2. (8 %) Revisión de la literatura, estado del arte y bibliografía	3
2.1. Fundamentos Teóricos y Aplicación Práctica	3
2.1.1. Redes Neuronales Convolucionales (CNNs)	3
2.1.2. Redes Neuronales Recurrentes (RNNs)	3
2.2. Estado del Arte	3
2.3. Contribución de la Revisión a la Investigación Actual	3
3. (20 %) Metodología de Investigación	4
3.1. Formación Conceptual	4
3.2. Diseño y Preparación de Datos	4
3.3. Entrenamiento del Sistema Neuronal	4
3.4. Análisis de Resultados	4
4. (13 %) Análisis de los datos	5
5. (10 %) Uso de la metodología y herramientas de aprendizaje estadístico	6
5.1. Selección de Herramientas	6
5.2. Librerías y Modelos Utilizados	6
5.3. Evaluación del Modelo y Verificación de Resultados	6
6. (20 %) Entregables y su descripción	6
7. (7 %) Conclusiones y trabajo futuro	7
7.1. Lecciones Aprendidas	7
7.2. Trabajo Futuro	7
8. (10 %) Ejecución del plan	8
8.1. Comparación del Plan Realizado con el Planeado	8
8.2. Lecciones Aprendidas de la Planificación	8
8.3. Imprevistos no Considerados	8
9. (2 %) Implicaciones éticas	9
10.(5 %) Aspectos legales y comerciales	10
10.1. Aspectos Legales	10

1. (5 %) Pregunta de investigación y objetivos

1.1. Objetivo Principal

El objetivo principal de este proyecto fue desarrollar y optimizar un modelo de Red Neuronal Convolutiva (CNN) robusto y eficiente para la identificación y clasificación precisa de las expresiones faciales en imágenes.

1.2. Objetivos Específicos

- **Comprender Teóricamente las CNNs:** Se realizó un estudio exhaustivo sobre los fundamentos matemáticos y conceptuales de las Redes Neuronales Convolucionales, incluyendo la teoría subyacente, el funcionamiento de las capas convolucionales, las funciones de activación más efectivas y los métodos de regularización y optimización utilizados. Este entendimiento teórico facilitó la implementación efectiva de la CNN para el reconocimiento de emociones.
- **Dominar los Conceptos Fundamentales de la Visión Artificial:** Profundizamos en los componentes críticos y fundamentales de la visión por computadora, tales como la adquisición de imágenes, preprocesamiento, extracción de características, segmentación y el reconocimiento y clasificación de objetos. Aplicamos estas técnicas para mejorar la precisión del modelo en la detección de emociones a partir de imágenes faciales.
- **Reconocer las Emociones Humanas mediante CNNs:** Demostramos experimentalmente que una máquina puede replicar la capacidad humana de distinguir emociones mediante la implementación de una CNN entrenada y validada con un conjunto de datos representativo. El modelo alcanzó una precisión significativa en la clasificación de emociones, lo que demuestra su viabilidad para aplicaciones en tiempo real.
- **Evaluar Alternativas en Aprendizaje Profundo:** Investigamos y comparamos el rendimiento de diferentes modelos de aprendizaje profundo y técnicas de optimización. Este análisis ayudó a identificar las fortalezas y limitaciones de diversas aproximaciones y a seleccionar la más adecuada para nuestro propósito específico de clasificación de expresiones faciales.
- **Implementación y Validación del Modelo:** El modelo de CNN fue diseñado, desarrollado y optimizado cuidadosamente para asegurar su replicabilidad y validación. Se realizaron múltiples pruebas y ajustes en los parámetros del modelo para mejorar la precisión, generalización y rendimiento. La metodología y las herramientas estadísticas empleadas garantizaron la integridad y la replicabilidad de los resultados.

2. (8 %) Revisión de la literatura, estado del arte y bibliografía

Se realizó una revisión exhaustiva de la literatura actual para asegurar una comprensión profunda de las últimas técnicas y desarrollos en el campo de la detección de emociones mediante el uso de redes neuronales. La investigación se centró en dos áreas principales: Redes Neuronales Convolucionales (CNNs) y Redes Neuronales Recurrentes (RNNs), esenciales para el procesamiento de imágenes y secuencias de datos, respectivamente.

2.1. Fundamentos Teóricos y Aplicación Práctica

2.1.1. Redes Neuronales Convolucionales (CNNs)

Se estudiaron en profundidad los fundamentos matemáticos y conceptuales de las CNNs a través de obras clave que ofrecen una visión detallada de la arquitectura y la funcionalidad de estas redes.

- *Neural Networks and Deep Learning* por Charu C. Aggarwal (2018) y Michael Nielsen (2021) fueron cruciales para entender las bases teóricas y las aplicaciones prácticas de las CNNs. Estos textos proporcionaron insights sobre cómo las capas convolucionales procesan las imágenes para extraer características relevantes para la clasificación de emociones.

2.1.2. Redes Neuronales Recurrentes (RNNs)

Para complementar el análisis de las CNNs, también se extendió la investigación a las RNNs, que son vitales para entender y procesar secuencias de datos, un componente esencial cuando se trata de analizar series temporales de expresiones faciales.

- Los mismos textos fundamentales sobre las CNNs también abordan las RNNs, ofreciendo métodos para mejorar el rendimiento del sistema al tratar con datos que tienen una dependencia temporal.

2.2. Estado del Arte

La revisión del estado del arte abordó las técnicas más recientes y cómo se han aplicado en proyectos similares para la detección de emociones. Esto incluyó el análisis de estudios recientes que utilizan CNNs y RNNs en diversas aplicaciones, desde la interacción humano-computadora hasta sistemas avanzados de vigilancia y asistencia sanitaria.

2.3. Contribución de la Revisión a la Investigación Actual

La literatura revisada no solo reforzó la base teórica del proyecto, sino que también guió el desarrollo experimental, ayudando a optimizar los algoritmos y ajustar los modelos para mejorar la precisión y eficiencia del sistema de detección de emociones desarrollado.

3. (20 %) Metodología de Investigación

La metodología empleada en este proyecto se centró en el desarrollo y optimización de un modelo de Red Neuronal Convolutiva para la detección y clasificación de emociones a partir de expresiones faciales. A continuación, se detallan los pasos seguidos en la investigación, desde la formación conceptual hasta el análisis de resultados.

3.1. Formación Conceptual

Se revisaron exhaustivamente las bases teóricas de las redes neuronales, especialmente las CNNs y RNNs, para fundamentar el desarrollo del modelo. Las principales fuentes incluyeron:

- **Neural Networks and Deep Learning** por Charu C. Aggarwal (2018).
- **URL:** <https://acortar.link/dQ5MQL>
- **Neural Networks and Deep Learning** por Michael Nielsen (2021).
- **URL:** <https://acortar.link/gCZAK3>

Estos textos proporcionaron la base teórica para el diseño y la configuración de las arquitecturas de red utilizadas en el proyecto.

3.2. Diseño y Preparación de Datos

- **Adquisición de Imágenes:** Se recopilieron dos conjuntos de datos amplios y diversificados de expresiones faciales, asegurando la representatividad de distintas demografías y condiciones de iluminación.
- **Preprocesamiento:** Incluyó la normalización de imágenes, ajuste de tamaño y aplicación de técnicas de reducción de ruido.
- **Preparación de Características:** Uso de capas convolucionales para identificar patrones y rasgos relevantes en las expresiones faciales.
- **Segmentación y División de las Imágenes:** Las imágenes fueron segmentadas para aislar características faciales importantes y divididas en conjuntos de entrenamiento y validación, los cuales recibieron algunas modificaciones para solucionar el desbalance que se presentó por pocas imágenes de algunos tipos de emociones.

3.3. Entrenamiento del Sistema Neuronal

- **Configuración de la Red:** Se configuró la arquitectura de la red con 6 capas convolucionales, funciones de activación ReLU y un aumento progresivo del número de filtros. Además de procesos de normalización por lotes, reducción de dimensionalidad y aplanamiento, con una función de activación final Softmax para conocer la probabilidad de cada clase.
- **Optimización:** Se utilizó el optimizador Adam estándar para encontrar el mejor valor de los parámetros y Dropout para evitar problemas de sobre ajuste durante el proceso de entrenamiento.

3.4. Análisis de Resultados

- **Evaluación del Modelo:** Se utilizaron las métricas de precisión y matriz de confusión que permitieron percibir el desempeño del sistema.
- **Interpretación de Resultados:** Análisis crítico de los resultados obtenidos y discusión sobre las mejoras que se pueden implementar al modelo para obtener un resultado más eficiente.

Este enfoque metodológico aseguró una investigación rigurosa y sistemática, permitiendo no solo desarrollar un modelo eficaz para la clasificación de emociones, sino también evaluar su aplicabilidad y limitaciones en escenarios reales.

4. (13 %) Análisis de los datos

Durante la fase de análisis de los datos, se identificaron patrones clave y áreas de mejora para el modelo de clasificación de emociones.

- **Evolución de la Exactitud y la Pérdida:** Las curvas de evolución de la exactitud y la pérdida revelan una mejora sostenida en la exactitud de entrenamiento y validación a lo largo de las épocas, alcanzando una precisión final en el conjunto de validación superior al 70 %. La estabilidad de la curva de pérdida y su decrecimiento constante indican una buena convergencia del modelo, aunque la persistencia de una brecha entre el entrenamiento y la validación sugiere un sobre ajuste moderado.
 - **Resultados de la Matriz de Confusión:** Las matrices de confusión para los conjuntos de entrenamiento y validación muestran una alta precisión en las categorías de emociones 'feliz' y 'sorpresa', mientras que las emociones 'triste' y 'neutral' presentan tasas más altas de confusión. Esto apunta a la necesidad de optimizar aún más el modelo para mejorar la discriminación entre emociones visualmente similares.
 - **Impacto del Aumento de Datos:** El análisis de las imágenes generadas artificialmente para el aumento de datos muestra una mejora significativa en la representación de clases minoritarias, lo que ayudó a reducir el desbalance del conjunto de datos y mejoró la generalización del modelo. Este enfoque fue crucial para equilibrar la precisión entre diferentes emociones, como se observa en la mejora de la precisión para clases previamente subrepresentadas.
 - **Interpretación de Predicciones:** El análisis de probabilidades de predicción para imágenes, proporcionó insights sobre la confianza del modelo en sus predicciones. La clara predominancia de la categoría feliz en las predicciones correctas contrasta con la distribución más uniforme en otras categorías, destacando la efectividad del modelo en ciertas emociones y sus limitaciones en otras.
- Estos resultados no solo validan la capacidad del modelo para clasificar emociones de manera efectiva, sino que también destacan aspectos críticos que requieren atención en futuras iteraciones del proyecto.

5. (10 %) Uso de la metodología y herramientas de aprendizaje estadístico

En el desarrollo de nuestro modelo de clasificación de emociones, se aplicaron técnicas de aprendizaje profundo mediante el uso de Redes Neuronales Convolucionales (CNN). La elección de herramientas y la metodología fueron diseñadas para asegurar la replicabilidad y la exactitud verificable de los resultados.

5.1. Selección de Herramientas

Se seleccionó TensorFlow junto con su API de alto nivel, Keras, debido a su capacidad de soporte para estructuras computacionales complejas y su extensa comunidad de usuarios. Esto facilita el experimento con diversas arquitecturas de CNN y permite una iteración rápida y eficiente. Keras proporciona una interfaz clara para definir rápidamente modelos y ejecutar entrenamientos de manera intuitiva.

5.2. Librerías y Modelos Utilizados

Se emplearon diversas librerías que complementan TensorFlow y Keras en el procesamiento de datos y análisis de resultados:

- **NumPy** y **Pandas** para la manipulación eficiente de datos.
- **Matplotlib** y **Seaborn** para visualizar los resultados y realizar análisis exploratorios de los datos.
- **Scikit-learn** para aplicar técnicas complementarias de aprendizaje automático y evaluación de modelos.

5.3. Evaluación del Modelo y Verificación de Resultados

El proceso de evaluación y verificación de los resultados del modelo incluyó técnicas clave para garantizar la confiabilidad y replicabilidad:

- **Medición de Accuracy:** Se monitoreó la precisión del modelo durante el entrenamiento y la validación, utilizando métricas de accuracy para evaluar la efectividad del modelo en clasificar correctamente las emociones.
- **Matrices de Confusión:** Se generaron matrices de confusión para los conjuntos de entrenamiento y validación para identificar cómo cada clase de emociones fue predicha por el modelo, facilitando la detección de clases que podrían estar siendo confundidas con otras.

Estas estrategias aseguran que el modelo no solo alcanza un rendimiento alto según las métricas estándar, sino que también es robusto y confiable bajo diversas condiciones de prueba, lo que es esencial para aplicaciones prácticas en la detección de emociones.

6. (20 %) Entregables y su descripción

- **URL Repositorio GitHub:** https://github.com/EsteArgen/Clasificador_Emociones_Firmas

7. (7%) Conclusiones y trabajo futuro

El proyecto ha logrado desarrollar un modelo de Red Neuronal Convolucional que identifica y clasifica emociones en expresiones faciales con una precisión considerable. A través del uso de TensorFlow y Keras, se implementó una arquitectura robusta que, combinada con técnicas de aumento de datos y validación cruzada, demostró ser efectiva en la mejora de la generalización del modelo sobre diversos conjuntos de datos.

Las matrices de confusión y los análisis de exactitud revelaron que, aunque el modelo es altamente eficaz en la identificación de ciertas emociones, como felicidad y sorpresa, enfrenta desafíos en distinguir entre emociones con expresiones faciales similares como tristeza y neutral. Esto subraya la complejidad inherente en la interpretación automática de las emociones humanas a través de expresiones faciales.

7.1. Lecciones Aprendidas

A lo largo del proyecto, se identificaron varias lecciones clave:

- La calidad y diversidad del conjunto de datos son cruciales para el entrenamiento de modelos de reconocimiento de emociones.
- La implementación de técnicas de regularización y normalización es fundamental para mitigar el sobreajuste y mejorar la capacidad de generalización del modelo.
- La visualización continua de los resultados durante el entrenamiento, utilizando herramientas como TensorBoard, es invaluable para el ajuste fino y la optimización del modelo en tiempo real.

7.2. Trabajo Futuro

Para futuras iteraciones del proyecto, se proponen las siguientes áreas de enfoque:

- **Exploración de Modelos Más Complejos:** Investigar arquitecturas de redes neuronales más avanzadas, como Inception que podría ofrecer mejoras significativas en la capacidad de distinguir entre emociones similares.
- **Ampliación del Conjunto de Datos:** Ampliar la colección de datos para incluir más variedad en términos de demografía, condiciones de iluminación y calidad de imagen para fortalecer la robustez del modelo.
- **Incorporación de Aprendizaje Multimodal:** Integrar otros tipos de datos, como el lenguaje corporal o el tono de voz, para mejorar la precisión en la detección de emociones, abordando la complejidad y multidimensionalidad de las expresiones emocionales humanas.
- **Desarrollo de una Aplicación en Tiempo Real:** Crear una aplicación que implemente el modelo en un entorno en tiempo real, permitiendo pruebas y ajustes continuos basados en la interacción del usuario.

En conclusión, este proyecto ha establecido una base sólida para el reconocimiento automático de emociones y ha destacado tanto sus potenciales como sus limitaciones, abriendo varias vías prometedoras para futuras investigaciones y aplicaciones prácticas.

8. (10 %) Ejecución del plan

- **URL GANTT:** <https://acortar.link/RkqWLa>

La ejecución del proyecto se llevó a cabo siguiendo un diagrama de Gantt que había sido planeado en la fase de anteproyecto. A lo largo del desarrollo, se realizaron ajustes significativos debido a diversos factores imprevistos y aprendizajes clave que influyeron en el proceso.

8.1. Comparación del Plan Realizado con el Planeado

Se incluye un diagrama de Gantt actualizado que refleja la ejecución real del proyecto. Comparado con el plan original, se observaron desviaciones en los tiempos de desarrollo y pruebas, principalmente debido a desafíos técnicos y retrasos en la obtención de datos.

8.2. Lecciones Aprendidas de la Planificación

- **Importancia de la Flexibilidad en la Planificación:** Aprendimos que los plazos deben ser flexibles para acomodar retrasos imprevistos, especialmente cuando se depende de la disponibilidad de datos externos o la colaboración de terceros.
- **Anticipación de Problemas Técnicos:** Los problemas técnicos, particularmente en la integración de nuevas tecnologías y librerías, fueron más frecuentes de lo esperado, lo que subraya la necesidad de incluir un tiempo adicional para la resolución de problemas en las fases iniciales del desarrollo.
- **Evaluación Continua del Progreso:** La implementación de revisiones periódicas del progreso resultó ser crucial. Estas revisiones ayudaron a ajustar el enfoque del proyecto conforme a las limitaciones emergentes y a reasignar recursos de manera más efectiva.
- **Recursos del sistema:** La ejecución del modelo en el entorno de Colab, requirió adquirir más recursos de cómputo con la versión Pro de esta, para poder tener estabilidad en las pruebas y validaciones del proyecto.
- **Preparación para la Escalabilidad:** Se reconoció la importancia de considerar la escalabilidad del sistema desde el principio, especialmente en proyectos que implican el procesamiento de grandes volúmenes de datos.

8.3. Imprevistos no Considerados

- La compatibilidad de ciertas librerías con las últimas versiones de herramientas de desarrollo, requirió una revisión y adaptación de algunas partes del código.

9. (2%) Implicaciones éticas

A lo largo del desarrollo de nuestro sistema de reconocimiento de emociones basado en Redes Neuronales Convolucionales, hemos profundizado en las implicaciones éticas asociadas con nuestra tecnología, atendiendo no solo a los avances tecnológicos, sino también a los desafíos éticos emergentes.

- **Sesgo y Discriminación:** El riesgo de sesgo y discriminación ha sido una preocupación constante. Hemos implementado revisiones de los datos de entrenamiento para asegurar su diversidad y representatividad, minimizando así el potencial de sesgos inherentes en el modelo. A pesar de estos esfuerzos, es crucial continuar con la monitorización y ajuste del sistema para evitar la perpetuación de estereotipos negativos o discriminación, especialmente en aplicaciones sensibles como la evaluación laboral o el acceso a servicios financieros.
- **Privacidad y Consentimiento:** El manejo ético de las imágenes faciales, que son consideradas datos sensibles, ha sido reforzado mediante la implementación de procedimientos estrictos de consentimiento. Debido a que se trata de un conjunto de datos público, todas las imágenes son de uso libre y no garantiza un riesgo, pero si se agregaran nuevas imágenes para evaluar el sistema, se debería garantizar el permiso de las personas para poder ser procesadas.
- **Transparencia y Responsabilidad:** Hemos incrementado la transparencia del proyecto mediante la documentación detallada del funcionamiento del modelo y los criterios utilizados para las decisiones automatizadas.
- **Impacto a Largo Plazo y Sostenibilidad:** Reflexionamos sobre el impacto a largo plazo de la tecnología de reconocimiento de emociones, considerando los efectos potenciales en la interacción social y la dinámica laboral. Es fundamental que, junto con el desarrollo tecnológico, se fomente una discusión abierta sobre las implicaciones morales y éticas de su aplicación. Esto incluye el desarrollo de directrices y políticas que promuevan un uso ético y responsable de la tecnología en diversos sectores sociales.

10. (5 %) Aspectos legales y comerciales

La integración del reconocimiento de emociones en servicios al cliente ha demostrado no solo ser viable, sino también transformadora. La capacidad de adaptar las respuestas en tiempo real según el análisis emocional ha mejorado la eficiencia y la efectividad en la atención al cliente, llevando a una satisfacción incrementada y relaciones más robustas con los usuarios. Más allá de las aplicaciones iniciales contempladas, hemos explorado nuevas áreas potenciales:

- **Personalización del Marketing Digital:** Utilizando el reconocimiento de emociones para ajustar y personalizar estrategias de marketing en tiempo real, aumentando la relevancia y el impacto de las campañas publicitarias.
- **Optimización de Interfaces de Usuario:** Aplicar esta tecnología en interfaces de usuario para software y plataformas en línea, donde el sistema puede adaptar dinámicamente la interfaz y los contenidos basados en el estado emocional del usuario.
- **Soporte Técnico y de Salud:** Implementar el reconocimiento de emociones en servicios de soporte técnico y aplicaciones de salud para mejorar la comunicación y ofrecer respuestas más empáticas y efectivas a los usuarios.

10.1. Aspectos Legales

La implementación de nuestra tecnología ha sido revisada bajo las perspectivas legales, con un enfoque en la protección de datos y la conformidad con regulaciones internacionales como el GDPR. A medida que la tecnología ha evolucionado, también lo han hecho nuestras estrategias para asegurar la legalidad de su uso:

- **Auditorías y Conformidad Continua:** Establecimiento de procesos regulares de auditoría para garantizar el cumplimiento continuo con el GDPR y otras normativas relevantes, ajustando nuestras operaciones, las actualizaciones legales y las mejores prácticas emergentes.
- **Desarrollo de Protocolos de Opt-Out:** Facilitar a los usuarios la opción de no participar en el proceso de recolección de datos emocionales, respetando su autonomía y derechos digitales.

Estos desarrollos no solo refuerzan la sostenibilidad legal y ética del proyecto, sino que también fortalecen su viabilidad comercial al asegurar la confianza y la fidelidad de las personas que posiblemente podrían utilizar el proyecto.